

OZ. 오즈코딩스쿨 X DACON AI 헬스케어 초격차 캠프

흡연 여부 예측 AI 해커톤

LAX, Lung Analytics eXpert
권형준 & 김빛나



보이는 수치로, 보이지 않는 습관을 밝히다.

- 01 — 팀 소개
- 02 — 프로젝트 개요
- 03 — 데이터셋 구성
- 04 — 흡연의 혈액 영향
- 05 — EDA 핵심 인사이트

- 06 — 피처 엔지니어링
- 07 — AutoGluon
- 08 — 모델 설정 및 학습
- 09 — 최종 성능과 순위
- 10 — 비하인드 스토리

| 팀 소개

“데이터로 숨결을 읽다.”

어쩌다 2인 팀 LAX, 건
강검진 데이터로 흡연 예측 도전



천재리더



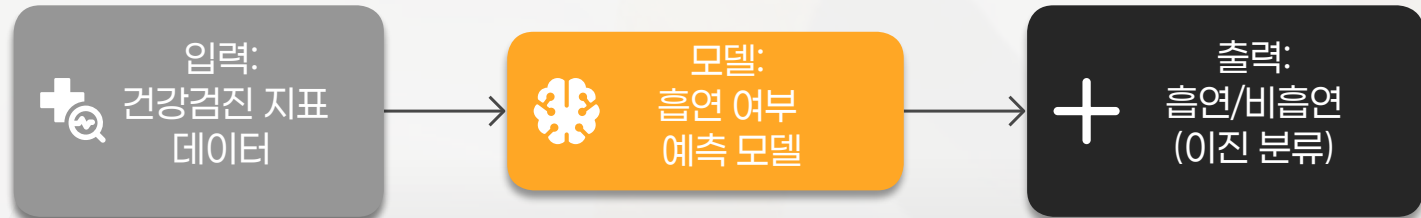
올라운더

| 프로젝트 개요

“건강 데이터에, 진심을 묻다.”

자가 보고 한계 극복을 목표로
데이터 기반 흡연 예측 모델 설계

흡연 여부 예측 모델 구축 과정




- 자가 보고 의존도를 줄이기 위한 흡연 여부 예측 모델
- 건강검진 지표만으로 흡연 상태를 이진 분류
- 공중 보건·개인 건강 관리·보험 등 실사용 시나리오 존재
- 최종 목표: 높은 Accuracy와 해석 가능한 피쳐 구조

데이터셋 구성

“숫자 속에, 사람의 습관이 숨어 있다.”

7천명·16개 변수,
비흡연 63%·흡연 37%의 불균형 구조



데이터 요약

데이터 분할 구조

• Train 7,000명/
Test 3,000명 구조

사용 변수 및 특징

• 16개 건강검진 변수: 혈액, 지질,
신체 측정 등 포함

리벨 분포 및 불균형

• 비흡연 63.3%,
흡연 36.7% (경도 불균형)

변수 특성 및 대리 변수

• 성별 변수는 없고,
키·가간접 대리 변수 역할

| 흡연의 혈액 영향

“혈액은, 거짓말을 하지 않는다.”

흡연으로 인한 COHb·저산소증·Hb 증가 메커니즘 정리



흡연이 혈액에 미치는 영향

담배 연기의 일산화탄소(CO)는 헤모글로빈에 산소보다 200배 강하게 결합하여 산소 운반 능력을 저하시킵니다.

보상 메커니즘

저산소증 → HIF-2 활성화 → EPO 생산 증가 → 적혈구/헤모글로빈 증가

지질대사 이상

중성지방 증가, HDL(좋은 콜레스테롤) 감소

HIF-2 몸이 산소 부족을 감지했을 때 활성화되는 전사조절 단백질
EPO : 신장에서 만들어지는 적혈구 생성 촉진 호르몬

흡연자 vs 비흡연자 차이

헤모글로빈 +1.28 g/dL ↑

저산소증 보상

중성지방 +38 mg/dL ↑

지질대사 이상

HDL -5.4 mg/dL ↓

좋은 콜레스테롤 감소

백혈구 +0.89 증가 ↑

염증 반응


출처: Nature Scientific Reports 2024, PMC Studies

EDA 핵심 인사이트

corr

- 라벨 분포 및 클래스 불균형 확인
- BMI·헤모글로빈 등 분포 시각화
- 이상치 탐지 및 의학적 범위 설정
- 피처 간 상관 및 상호작용 분석

```
In[67]: plt.figure(figsize = (12,8), dpi = 100)
sns.heatmap(data.drop('ID', axis = 1).corr(), annot = True, cmap = 'Blues')
plt.show()
```



EDA 핵심 인사이트

MI


- 라벨 분포 및 클래스 불균형 확인
- BMI·헤모글로빈 등 분포 시각화
- 이상치 탐지 및 의학적 범위 설정
- 피처 간 상관 및 상호작용 분석
- 두 변수 사이에 비선형 관계까지 포함한 피처 의존도를 측정
- 피처 제거 시도 👉 시력, 혈압, 요 단백, 저밀도지단백

```
[469...] from sklearn.feature_selection import mutual_info_regression
import pandas as pd

X, y = data.drop(['ID', 'label'], axis = 1), data['label']
mi = mutual_info_regression(X, y)

mi_series = pd.Series(mi, index=X.columns)
mi_series.sort_values(ascending=False)

mi_series.sort_values().plot(kind = 'barh', figsize=(8,6))
plt.title("Mutual Information Scores")
plt.show()
#MI 두 변수 사이에 비선형 관계까지 포함한 의존성을 측정하는 값
#제거해도 되는 것 from MI : 충치, 저밀도지단백, 나이, 콜레스테롤, 혈압, 시력, 공복혈당, 간 효소율
```



EDA 핵심 인사이트

Pearson, Spearman, P-value

- 라벨 분포 및 클래스 불균형 확인
- BMI·헤모글로빈 등 분포 시각화
- 이상치 탐지 및 의학적 범위 설정
- 피처 간 상관 및 상호작용 분석

```
[330]: #id, label 빼고 상관관계 측정
from scipy.stats import pearsonr, spearmanr
results = []

for a in data.drop({'ID', 'label'}, axis = 1).columns:
    pair = data[[a, "label"]].dropna().copy()
    pair = pair.apply(pd.to_numeric)
    r, p = pearsonr(pair[a], pair["label"])
    rho, p2 = spearmanr(pair[a], pair["label"])
    results.append([a, r, p, rho, p2])

df_coff = pd.DataFrame(results, columns=['이름', 'pearson r', 'p value', 'spearman r', 'p value'])
df_coff.sort_values('pearson r', ascending=False)

#pearson 상관계수 - 선형관계일 때
#spearman 상관계수 - 비선형 관계일 때


#제거해도 되는 것 from MI : 총치, 저밀도지단백, 나이, 콜레스테롤, 혈압, 시력, 공복혈당, 간 효소율
#제거해도 되는 것 from pearson: 간 효소율, 고밀도지단백, 나이, 저밀도지단백, 콜레스테롤, 요 단백질, 혈압, 총치
#제거해도 되는 것 from feature importance: 간 효소율, 고밀도지단백, 나이, 저밀도지단백, 콜레스테롤, 요 단백질
#3 개다 포함되는건? 나이(3), 저밀도지단백(3), 간 효소율(3), 총치(2), 혈압(2), 콜레스테롤(2)
```

[330]:	이름	pearson r	p value	spearman r	p value
13	헤모글로빈	0.402002	3.321253e-270	0.414942	1.678166e-289
1	키(cm)	0.394669	1.205397e-259	0.400314	9.460852e-268
2	몸무게(kg)	0.311503	2.396700e-157	0.328154	2.119559e-175
8	중성 지방	0.247918	1.552824e-98	0.252511	2.864160e-102
9	혈청 크레아티닌	0.197585	1.472581e-62	0.275094	9.066992e-122
3	BMI	0.126438	2.423867e-26	0.132428	9.297786e-29
6	공복 혈당	0.112261	4.486224e-21	0.106178	5.238338e-19
5	총치	0.098468	1.493128e-16	0.098468	1.493128e-16
4	시력	0.073323	8.158929e-10	0.119655	9.630763e-24
7	혈압	0.019119	1.097208e-01	0.028426	1.739175e-02
14	요 단백질	-0.004987	6.765730e-01	-0.009177	4.426804e-01
10	콜레스테롤	-0.009176	4.427459e-01	-0.009465	4.284907e-01
12	저밀도지단백	-0.032728	6.172127e-03	-0.040679	6.634220e-04
0	나이	-0.174694	4.345031e-49	-0.175481	1.599624e-49
11	고밀도지단백	-0.180835	1.573073e-52	-0.192129	3.459760e-59
15	간 효소율	-0.183779	3.183372e-54	-0.209446	3.088611e-70

EDA 핵심 인사이트

Outlier

- 라벨 분포 및 클래스 불균형 확인
- BMI·헤모글로빈 등 분포 시각화
- 이상치 탐지 및 의학적 범위 설정
- 피쳐 간 상관 및 상호작용 분석



```
• [442...] col = '중성 지방'

Q1 = X[col].quantile(0.25) #quantile: 전체 데이터중 25퍼센트 지정과
Q3 = X[col].quantile(0.75) #quantile : 전체 데이터중 75퍼센트 지정에서
IQR = Q3 - Q1


upper = Q3 + 2 * IQR # 박스플롯 위쪽
down = Q3 - 2 * IQR # 박스플롯 아래쪽

mask = (X[col] <= upper) & (X[col] >= down)

X_clean = X[mask].copy()
y_clean = y[mask].copy()

print("원래 개수:", len(X))
print("제거 후 개수:", len(X_clean))
print("제거 후 개수:", len(y_clean))


원래 개수: 7000
제거 후 개수: 6846
제거 후 개수: 6846
```



피쳐 엔지니어링

“버림의 미학이, 정확도를 만든다.”

BMI 공선성을 확인하고 제거해
모델의 정확도·해석 향상



	이름	pearson r	p value	spearman r	p value
13	헤모글로빈	0.402002	3.321253e-270	0.414942	1.678166e-289
1	키(cm)	0.394669	1.205397e-259	0.400314	9.460852e-268
2	몸무게(kg)	0.311503	2.396700e-157	0.328154	2.119559e-175
8	중성 지방	0.247918	1.552824e-98	0.252511	2.864160e-102
9	혈청 크레아티닌	0.197585	1.472581e-62	0.275094	9.066992e-122
3	BMI	0.126438	2.423867e-26	0.132428	9.297786e-29
6	공복 혈당	0.112261	4.486224e-21	0.106178	5.238338e-19
5	총치	0.098468	1.493128e-16	0.098468	1.493128e-16

주요 발견

1. 헤모글로빈이 가장 강력한 예측 변수
2. 키는 성별(남성) proxy 역할
3. 지질 관련 변수들도 유의미

! BMI 제거 이유

BMI = 몸무게 / 키²
키, 몸무게와 완전 상관 → 다중공선성

! 추가 제거 피쳐

시력 + 요 단백질
상관관계 낮은 피쳐들 + 제외
정확도 ↑

흡연과의 상관관계 (Pearson r)

헤모글로빈 +0.40 ★

키(cm) +0.39

중성지방 +0.25

HDL -0.18

간효소율 -0.18

모델 설정 및
학습

Grid Search 이용해 최대한의 하이퍼 파라미터 찾을

- 가장 잘 나왔던 피쳐들 리더보드 0.754 기록

“모델 위

4단계 스텝
다양한 모델

```
[24]: from sklearn.model_selection import GridSearchCV
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import GradientBoostingRegressor, RandomForestRegressor
from catboost import CatBoostRegressor
from sklearn.tree import DecisionTreeRegressor
from xgboost import XGBRegressor

model = XGBRegressor()
param_grid = {
    'n_estimators': [10, 30, 50],
    'learning_rate': [0.5, 0.1, 0.3],
    'max_depth': [1, 2, 3]
}

grid_search = GridSearchCV(
    estimator=model,
    param_grid=param_grid,
    cv=5,
    scoring='r2',
)

import pandas as pd
data = pd.read_csv('train.csv')
X, y = data.drop(['ID', 'label', '나이', 'BMI', '시력', '충치', '공복 혈당', '혈압', '콜레스테롤', '고밀도지단백', '저밀도'])
grid_search.fit(X, y)
print(f'최적 파라미터: {grid_search.best_params_}')
print(f'{grid_search.best_score_:.3f}')
print(f'{grid_search.best_estimator_}')

최적 파라미터: {'learning_rate': 0.1, 'max_depth': 3, 'n_estimators': 50}
0.252
XGBRegressor(base_score=None, booster=None, callbacks=None,
              colsample_bylevel=None, colsample_bynode=None,
              colsample_bytree=None, device=None, early_stopping_rounds=None,
              enable_categorical=False, eval_metric=None, feature_types=None,
              feature_weights=None, gamma=None, grow_policy=None,
              importance_type=None, interaction_constraints=None,
              learning_rate=0.1, max_bin=None, max_cat_threshold=None,
              max_cat_to_onehot=None, max_delta_step=None, max_depth=3,
              max_leaves=None, min_child_weight=None, missing=nan,
              monotone_constraints=None, multi_strategy=None, n_estimators=50,
              n_jobs=None, num_parallel_tree=None, ...)
```

```
base_models2 = [
    ("LGBM", LGBMClassifier(
        learning_rate=0.05,
        n_estimators=300,
        objective="binary",
        n_jobs=-1,
        random_state=42,
    )),
    ("XGB", XGBClassifier(
        n_estimators=600,
        learning_rate=0.02,
        max_depth=5,
        subsample=0.8,
        colsample_bytree=0.8,
        tree_method="hist",
        eval_metric="logloss",
        random_state=42,
    )),
    ("CAT", CatBoostClassifier(
        depth=8,
        iterations=800,
        l2_leaf_reg=1,
        learning_rate=0.01,
        verbose=0,
        loss_function="Logloss",
        eval_metric="AUC",
        random_seed=42,
    )),
    ("ET", ExtraTreesClassifier(
        n_estimators=400,
        min_samples_split=2,
        min_samples_leaf=2,
        max_features="sqrt",
        bootstrap=True,
        n_jobs=-1,
        random_state=42,
    )),
    ("RF", RandomForestClassifier(
        n_estimators=500,
        max_depth=None,
        min_samples_split=2,
        min_samples_leaf=2,
        max_features="sqrt",
        n_jobs=-1,
        random_state=42,
    )),
]
```

- 피쳐 제거하고 각 모델 별 정확도 점검

```
[328]: test = pd.read_csv('test.csv')
test_X = test[X.columns]

y_pred = stacking.predict(test_X)

submit = pd.read_csv('sample_submission.csv')
submit['label'] = y_pred
submit.head()
submit.to_csv('submission4.csv', index = False)
```

1차
LGBR : 0.2658 (+/- 0.0129)
XGBR : 0.2514 (+/- 0.0119)
CAT : 0.2739 (+/- 0.0152)
ETR(EXTRATRESS REGRESSOR): 0.2755 (+/- 0.0126)
RANDOMF : 0.2810 (+/- 0.0134)

2차 피쳐 많이 제거
stacking 모델 이름lsvc, 정확도: 0.7351055856223834

3차 피쳐 조금 제거
stacking 모델 이름lsvc, 정확도: 0.7404285714285714

4차 피쳐 제거 노
stacking 모델 이름lsvc, 정확도: 0.7373390557939914

5차 피쳐 제거: 조금 (혈압, 충치, 간 효소율) 결측치 제거 노
stacking 모델 이름lsvc, 정확도: 0.7396280400572246

6차 피쳐 제거 : 조금 (혈압, 충치, 간 효소율 + 결측치 제거) + 결측치 상위 20위로 다
stacking 모델 이름lsvc, 정확도: 0.735852079755122

AutoGluon 개요

“자동화는 게으름이 아니라, 전략이다.”

AutoGluon 기반으로 전략을 전환해
수동 튜닝 없이 성능 향상

AutoGluon 구조

- 1.데이터 셔플
- 2.NA 결측치 처리
- 3.범주형 인코딩
- 4.하이퍼 파라미터를 직접 모델링
- 5.stacking 앙상블 학습
- 6.가중치 앙상블 학습



AutoGluon 적용 과정

“자동화는 게으름이 아니라, 전략이다.”

AutoGluon 기반으로 전략을 전환해
수동 튜닝 없이 성능 향상


AWS 개발 AutoML 프레임워크

하이퍼파라미터 최적화(HPO)에 의존하지 않고, 다양한 모델 학습 + Bagging + Stack Ensembling으로 성능 달성

3가지 핵심 원리

1. 다양한 모델 학습 (CatBoost, XGB, RF, NN...)
2. Bagging으로 각 모델 안정화
3. Multi-layer Stacking으로 결합

Multi-layer Stacking 구조



모델 설정 및 학습

“모델 위에 모델을 쌓다, 정교함을 얻다.”

4단계 스택킹 구조 도입으로
다양한 모델의 강점을 통합해 정확도 확보



설정 상세 설명

eval_metric='accuracy'

대회 평가지표와 일치

time_limit=300

5분이 최적 (너무 길면 과적합)

num_stack_levels=3

4단계 스택킹 (L1~L4)

presets='best_quality'

8-fold bagging, 최고 품질 설정

핵심 코드


```
predictor = TabularPredictor(  
    label='label',  
    eval_metric='accuracy', # 핵심!  
    problem_type='binary' #2진 분류 모델인거 명확히 지정  
)  
.fit(  
    train_data=train,  
    time_limit=300, # 5분 #700 ⬅ 600 ⬅ 500 ⬅ 400 ⬅ 300 ⬅ 200 전부 실험  
    num_stack_levels=3,  
    presets='best_quality' #가장 느리지만 가장 정확  
)
```

흡연 여부 예측
AI 해커톤
: LAX, Lung
Analytics eXpert

모델 설정 및 학습

“모델 위에 모델을 쌓다, 정교함을 얻다.”

4단계 스택킹 구조 도입으로
다양한 모델의 강점을 통합해 정확도 확보



모델 설정 및 학습

“모델 위에 모델을 쌓다, 정교함을 얻다.”

4단계 스택킹 구조 도입으로
다양한 모델의 강점을 통합해 정확도 확보

```
[450]: predictor = TabularPredictor(  
        label=label_col, eval_metric='accuracy', problem_type='binary').fit(  
        train_data=train,  
        time_limit=300,  
        num_stack_levels = 3,  
        presets="best_quality",  
    )
```

```
No path specified. Models will be saved in: "AutogluonModels/ag-20251126_100821"  
Verbosity: 2 (Standard Logging)  
===== System Info =====  
AutoGluon Version: 1.4.0  
Python Version: 3.10.15  
Operating System: Darwin  
Platform Machine: arm64  
Platform Version: Darwin Kernel Version 25.1.0: Mon Oct 20 19:32:41 PDT 2025; root:xnu-12377.41.6~2/RELEASE_ARM64_T8040  
CPU Count: 10  
Memory Avail: 5.67 GB / 16.00 GB (35.4%)  
Disk Space Avail: 297.88 GB / 460.43 GB (64.7%)  
===== Presets specified: ['best_quality']  
Using hyperparameters preset: hyperparameters='zeroshot'  
Setting dynamic_stacking from 'auto' to True. Reason: Enable dynamic_stacking when use_bag_holdout is True  
Stack configuration (auto_stack=True): num_stack_levels=3, num_bag_folds=8, num_bag_sets=1  
DyStack is enabled (dynamic_stacking=True). AutoGluon will try to determine whether the input data is  
able or disable stacking as a consequence.
```

```
[451]: leaderboard = predictor.leaderboard(train, silent=True)  
print(leaderboard)
```

| 최종 성과와 순위

- 모델 앙상블 ACC 향상
- Threshold 최적화로 Accuracy 향상
- 현재 리더보드 1위 달성
- 제출 전략 및 지속 모니터링
- 피쳐 엔지니어링, 하이퍼 파라미터, 지표 수정 계속 거쳐서 데이터 점수 증가시킴
- 추가로 적용해 보면 좋을 점:
- 추가 전처리 적용
- 파생변수 생성 후 학습

```
[342]: from autogluon.tabular import TabularDataset, TabularPredictor
#요거는 건들지 마!@!@!

train.drop(['ID', 'label', 'BMI', '시력', '요 단백질'], axis = 1, inplace=True) #inplace True 하면 train = train~~ 할 필요가 없어짐
```

```
#키 몸무게 제거 🏹 LightGBM_BAG_L4    0.999571    0.767143    accuracy
#BMI 제거 🏹 CatBoost_BAG_L4    1.000000    0.771857    accuracy
#BMI, 총치 제거 🏹 ightGBM_BAG_L4    0.999857    0.766714    accuracy
#헤모글로빈 제거 🏹 XGBoost_BAG_L4    0.993571    0.758143    accuracy
#BMI, 시력 제거 🏹 WeightedEnsemble_L5    0.995714    0.773857    accuracy
#BMI, 시력, 요 단백질, 🏹 WeightedEnsemble_L5    0.994429    0.776429    accuracy
#BMI, 시력, 요 단백질, 공복 혈당 🏹 WeightedEnsemble_L2    0.948571    0.752000    accuracy
#BMI, 시력, 요 단백질, 중성 지방 🏹 LightGBM_BAG_L4    0.999571    0.774571    accuracy
#BMI, 시력, 요 단백질, 저밀도지단백 🏹 NeuralNetTorch_r79_BAG_L1    0.755000    0.742000    accuracy
#BMI, 시력, 요 단백질, 콜레스테롤 🏹 WeightedEnsemble_L5    0.994000    0.772857    accuracy
#BMI, 시력, 요 단백질, 간 효소율 🏹 WeightedEnsemble_L5    0.998429    0.772000    accuracy
#BMI, 시력, 요 단백질, 나이 🏹 WeightedEnsemble_L5    0.998571    0.763714    accuracy

####요 아래부터 BMI, 시력, 요 단백질 제거
#중성지방 outlier 처리 LightGBMXT_BAG_L4    0.986286    0.775507    accuracy
#
```


| 갈등과 화해

- 순위 하락으로 서로를 탓하는 분위기
- 장문 메시지로 감정 해소
- 리더가 책임을 약속하고 배려 강화
- 화해 후 팀워크 회복



11월 25일 화요일

밋나킴

오전 11:44

어제 수정해서 리더보드에 올린 건, 저도 충분히 다들지 못한 상태라는 걸 알면서도 주어진 기회를 그냥 두기 아까워서 일단 한 번 제출해봤습니다.

주말에 과외 9시간씩 하면서도 틈틈이 계속 수정하고 있었고, 지금도 모델 구조랑 하이퍼 파라미터 쪽 더 손보면서 다시 돌리고 있는 중이에요.

어제 제출본은 제 판단이 아주 신중하진 못했던 건 맞지만, 기회를 전부 소진한 것도 아니고, 현재 우리의 최종 성과를 방해했다거나 누군가를 탓해야 할 상황이라고 보진 않습니다.

대회 자체가 원래 변동도 크고, 성과를 잘 못 내는 건 우리 팀뿐만의 문제도 아니니까, 서로 최대한 열심히 하되 "누가 더 잘했다/못했다" 식으로 서로를 탓하는 분위기는 안 됐으면 좋겠습니다.

지도 가능한 한 성과를 내려고, 무거운 모델들로 여러 버전 돌려보고 있고 한 번 돌리는 데 시간 많이 걸린다는 거 아시잖아요.

그리고 "세 번 다 기회 쓰더라도, 제출 전에 무조건 먼저 보여주고 해라" 같은 식의 말은 말로만 오가면 나중에 기록도 안 남고, 괜한 오해나 분만이 생길 수 있어서요.

이런 부분은 앞으로 **솔에 글로 남기면서** 논의하는 방향이면 좋겠습니다. (제출 기준, 공유 방식 등 합의가 필요하다면 여기서 같이 정하면 될 것 같아요.)

저는 개인적으로 순위권에 들겠다는 욕심이 엄청 크진 않지만, 형준님께서 순위 욕심 내주시는 건 이해하고 있고, 그 기대에 맞춰서 지도 있는 최선을 다해보겠습니다.

여건이 안 좋긴 않지만, 서로 존중하면서 끝까지 한 번 밀어붙여봐요. 고생 많으시고, 우리 끝까지 파이팅합시다.

4개 파일

image.png

PNG

01

LAX_1125_8_6.ipynb

이전

11월 25일 화요일

권형준0626

오전 11:49

저 정말 괜찮아요~ 저도 계속 바뀌는데 안 되서 오늘 오전부터는 하는거 어떻게 바꿨는지 다 기록하면서 하는 중입니다.

1차

LGBR : 0.2658 (+/- 0.0129)

XGBR : 0.2514 (+/- 0.0119)

CAT : 0.2739 (+/- 0.0152)

ETR(EXTRATRESS REGRESSOR): 0.2755 (+/- 0.0126)

RANDOMF : 0.2810 (+/- 0.0134)

2차 피쳐 많이 제거

stacking 모델 이름lsvc, 정확도: 0.7351055856223834

3차 피쳐 조금 제거

stacking 모델 이름lsvc, 정확도: 0.7404285714285714

4차 피쳐 제거 노

stacking 모델 이름lsvc, 정확도: 0.7373390557939914

5차 피쳐 제거: 조금 (혈압, 충치, 간 효소율) 결측치 제거 노

stacking 모델 이름lsvc, 정확도: 0.7396280400572246

6차 피쳐 제거: 조금 (혈압, 충치, 간 효소율 + 결측치 제거) + 결측치 상위 20위로 다 제거

stacking 모델 이름lsvc, 정확도: 0.735852079755122

| 우승 전략

- AutoGluon 기반 AutoML 적용
- 수작업 대신 AutoML로 0.76533 ACC 달성
- 전략 전환 후 5위-> 2위 -> 1위 복귀

흡연 여부 예측
AI 해커톤
: LAX, Lung
Analytics eXpert



| 순위 변화 이야기

- 초반 리더보드 1위 달성
- 이후 5위까지 하락하며 불안정
- 성과 압박과 피로가 커짐
- 순위 변화 타임라인 공유

와

오토글루온 그냥 넣고

AH_01_김빛나!

오후 05:46

그니까

ㅋㅋㅋㅋ

AH_01_권형준

오후 05:47

최고모델 cat 부스트 최고모델나온거가지고

잠시만요

AH_01_김빛나!

오후 05:47

와 되요? 우리 학습중이라서

버벅

아 어디야

AH_01_김빛나!

오후 05:51

우리 2등하고 있었네?

흡연 여부 예측
AI 해커톤
: LAX, Lung
Analytics eXpert

| 인사이트·한계·확장

- 전략 연구: 검증된 해법에서 출발
- 도구 활용: AutoML과 manual의 균형
- 팀워크: 갈등→화해→신뢰 회복
- 향후: 추가 피쳐, 다른 AutoML, 실제 데이터 적용



OZ. 오즈코딩스쿨 X DACON AI 헬스케어 초격차 캠프

헬스케어 데이터 기반 인공지능 디지털 의료 웹 서비스 개발자 양성과정

AI 헬스케어 초격차 캠프

경청해주셔서 감사합니다