

Fall risk prediction using temporal gait features and machine learning approaches

Frontiers 2024

2026.02.18

Presenter: Hyungjun Kwon



Contents

- 1. Introduction
- 2. Problem Formulation
- 3. Methodology
- 4. Experiment
- 5. Conclusion

Why LightGBM

Gait data, including gyroscope, accelerometer, cadence, and temporal cycle information, contains **a large number of features**

+

and forms a high-dimensional dataset. Therefore, a single unified LGBM model was adopted to **simplify the training process** and reduce **computational time**.

leaf-wise method: from decision tree model, especially in GBDT, brings the highest reduction in the loss function



1. leaf-wise method
2. Bin – split method

bin - split method

연속 수치형 데이터는 트리 모델에서 일단 시간이 너무 많이 걸림 → bin으로 묶어서 시간을 최소화 + predict loss가 최소화되는 부분으로 bin split



Problem Formulation

Problem: Traditional clinical fall-risk assessments are resource-intensive, time-consuming, and require trained personnel.

Challenge: The dataset is highly imbalanced, with many fallers but very few non-fallers.

Solution: Gait features were extracted from video-based pose estimation and SMOTE with LightGBM was used for fall-risk classification.

Methodology (Previous Research)

cnn 은 팔을 올리고 있는 사진 가지고,
팔을 올리는 중인지 내리는 중인지 판
단 불가

2022 Choi et al.

데이터셋 및 구성

참가자 20명, 1,200개 샘플 수집.
Near-fall 및 비낙상 ADL 활동 포함하여 다양성 확보.

모델 아키텍처

DAG-CNN (Directed Acyclic Graph)

복잡한 신호 패턴 학습을 위한 그래프 신경망 구조.

Accuracy

98.0%

* 베이스라인 CNN(69.8~89.7%) 대비 월등한

cnn 모델은 마지막 층 특징만 결과
값으로 사용, cnn-dag 모델 사용시

초기에 저수준 특징과 후반의 고수

준 특징을 모두 학습해 정보 손실 줄

이고 정확도 향상 가능

resnet 같이 skip connection 모
델중 하나

2023 Philip et al.

데이터셋 및 구성

공개 데이터셋 활용 (웨어러블 센서).
자이로스코프 및 가속도계 데이터, 20명 대상.

모델 아키텍처

CNN + RNN (Hybrid Model)

CNN으로 특징 추출 후 RNN으로 시계열 의존성 학습.

Accuracy

95.0%

AUC-ROC

0.98

+ 장점

시계열 특성 반영, 높은 신뢰도

- 한계

데이터 규모 제한, 환경 문맥 미고려

cnn-rnn 입력 = image sequence

->from images feature extract

->시간에 따라 변화는 자세 정보

→ 시계열 관련 데이터(속도변화, 가
속, 흔들림, 반복 패턴 등)

→ 영상 전체 요약 벡터를 softmax 로
결과 도출 → walking, sitting 판단

Methodology(Detail of method)

$\text{coords[:, :, 1]} = \text{savgol_filter}(\text{coords[:, :, 1]}, 7, 2)$
= 1(y 축을) 기준으로 7프레임을 2차원 함수로 smoothing 한다

halpe full body 출력 좌표 $\text{coords.shape} = (\text{프레임 수}, \text{관절 갯수}, \text{x-y축})$
실제 움직이는 좌표화, 필터에 찍히는 좌표 차이 노이즈 발생
이를 완화하기 위해 SG 필터 도입




FIGURE 3
Halpe Full Body model output and keypoint illustration.

1. **Halpe Full Body** is used as a posture-tracking model for video processing frame by frame

2. The output generates 26 key points including nose, shoulders, elbows, hips, toes.

[https://github.com/MVIG-SJTU/AlphaPose\(alpha pose - halpe full body\)](https://github.com/MVIG-SJTU/AlphaPose(alpha%20pose%20-%20halpe%20full%20body))

보행 → periodic motion 주기운동인데


moving average filter 쓰게되면, peak 삭제 보행 feature extraction unavailable

가우시안 필터 → 고주파 제거 필터 사용? → 낙상 특이 feature 고주파에서 coincidently 하게 발생 but gaussian 에 의해 제거됨
but SG 필터? → 주변 다항식 에 맞춰서 곡선을 재구성 하는 필터

Methodology(Detail of method)

- $\hat{y}_i$ =smoothed value at the i index position in the data series
 - c_j =filter coefficients(상관계수)
 - y_{i+j} =data points in the neighborhood of the central point i (Pelliccia, 2019).

$$\hat{y}_i = \sum_{j=-k}^k c_j \cdot y_{i+j} \quad (1)$$



1. **Savitzky-Golay (SG) filter** is used for reducing noise and improving signal smoothness

2. 카메라로 얻은 발뒤꿈치 좌표가 프레임마다 흔들리기 때문에
→ heel strike / toe off 검출을 정확하게 하기 위해 신호를 매끈하게 만드는 단계

Methodology(Detail of method)

회전 데이터 제외 알고리즘 전체 흐름

1. **Input:** Raw Heel Coordinates



2. **Smoothing:** Savitzky-Golay Filter (고주파 제거, 주기성 형성)



3. **Peak Detection:** Find Local Maxima (발 디딤 구간 찾기)



4. **Identification:** Detect pivot heel strike (turning point) and determine pivot foot by comparing right and left heel signals



5. **Expansion:** Find Prev/Next Peaks surrounding the turn



6. **Calculation:** Compute Median Indices(그 사이 프레임 제거 목적)



7. **Output:** Turn Start/End Frames

Methodology(Datasets)

데이터셋	역할
MMU-FRiP (21명)	Non-fallers (정상군) -> 실제실험
Mendeley (44명)	Fallers (낙상 위험군)

Methodology(Oversampling)

Oversampling 완화 위해 SMOTE 기능 사용

Data number too small -> overfitting -> generalization needed

SMOTE = Synthetic Minority Over-Sampling Technique

= 소수 데이터 클래스 데이터를 '복사'가 아니라 '합성'해서 늘리는 방법

= Generate additional imaginary patients(normal)


= 총 65개 실제 데이터에서 SMOTE 하여 88개의 총 데이터셋 생성

$$\text{New} = A + r \times (B - A)$$

r은 랜덤 값

기존 데이터의 기하학적 모양을 유지하면서 밀도를 증가시키는 방법
중요! smote 는 반드시 train 에만 적용. test 에 쓰면 논문 reject 가능성 업

Methodology(Experiments)



Methodology(Coefficients)



1. Cadence, right strike time, left stride time, left step time, right step time, right stance time, left stance time
2. Cadence has strong negative relationship with stride and step time.
3. Cadence has weak relation with stance time.

Methodology(Evaluation-stance time)

Distribution of Right Stance Time




FIGURE 7

Distribution of stance times for fallers and non-fallers.

1. 낙상 위험군은 stance time이 특정 값에 몰리며 보행 변동성이 감소하는 경향을 보인다. 즉 일정하고 경직된 보행 패턴이 낙상 위험의 특징이다
2. 비 낙상군은 각 보폭마다 다른 상황에 따른 stance time 을 조절할 수 있어 비교적 넓은 stance time 분포를 갖는다

right stance time - 오른발이 바닥에 붙어있는 시간
곡선을 만들기 위해 분포를 잡아보니 - stance time이 찍히는 것처럼 보임
실제 stance time data 는 모두 positive
데이터를 도식적으로 부드럽게 표현하다 보니 생긴 happening

Methodology(Evaluation-stride time)

Distribution of Right Stride Time





FIGURE 8
Distribution of stride times for fallers and non-fallers.

1. 같은 발이 다시 땅에 닿기까지의 시간 = stride time 에서도 낙상 위험군이 상대적으로 일정한 stride time 을 갖는다

Methodology(Evaluation-step time)

Distribution of Right Step Time



1. stride time stance time 과 유사하다

FIGURE 9
Distribution of step times for fallers and non-fallers.

Methodology(Evaluation-stride time)

Distribution of Cadence




FIGURE 10

Distribution of cadence for fallers and non-fallers.

1. 이것도 유사하다 but coefficient 가 stance time, step time 과 반대로 진행되었다. 이는 낙상 위험군의 데이터 분포가 상대적으로 낮았던 이전 데이터에 비해 분당 걸음수 cadence 에서는 더 큰 것을 볼 수 있다

Methodology(Standard-Scaler)




FIGURE 12
Comparison of original data distributions and scaled data distributions.

1. cadence 가 다른 피쳐들에 비해 x 축으로 넓게 분포되었기에, 모델이 학습하는데 지장 없도록 하기 위해서 전체 데이터 분포를 평균 0, 표준편차 1로 맞춰서 normalization

Methodology(SMOTE sampling)




FIGURE 11
Comparison of original data and SMOTE sampled data.

1. SMOTE sampling made 21 non-fallers / 44 fallers to 44 non-fallers, 44 fallers


Methodology(modeling comparison)

TABLE 4 Accuracy comparison.

	AdaBoost	Bagging	CatBoost	Decision Tree	KNN	LightGBM
Experiment 1	0.81	0.89	0.89	0.81	0.96	0.96
Experiment 1 without SMOTE	0.95	1.00	1.00	0.95	1.00	1.00
Experiment 1 without enhancement	0.95	1.00	1.00	0.95	0.80	1.00
Experiment 1 without feature scaling	0.81	0.89	0.89	0.81	0.78	0.96
Experiment 2	0.81	0.89	0.89	0.89	0.93	0.96
Experiment 2 without SMOTE	0.90	1.00	0.95	0.95	1.00	1.00
Experiment 2 without enhancement	0.90	1.00	0.95	0.95	0.70	1.00
Experiment 2 without feature scaling	0.81	0.89	0.89	0.89	0.78	0.96

The bold values represent the accuracy score achieved by our proposed LightGBM model, as well as the highest score obtained in every experiment.

Methodology(feature importances)





Conclusion

Contribution

1. **LightGBM** demonstrates remarkable efficacy and performance in classification, attaining 96% accuracy in both experiments
2. There is possibility that **longer cadence** as well as shorter step times could increase an individual's risk of falling

Limitations

1. overfitting issue caused by the limited dataset reliance on synthetic data, and lack of diversity in the dataset



Thank you for listening